

Projeto CRISP-DM – ETAPA 5

Equipe: Ana Julia Lidório, João Gustavo Vitali e Lara Dondossola

Parte 1 - GERAL

1) Qual era a pergunta principal da equipe?

A pergunta central que guiou todo o projeto desde o início foi: "Existem disciplinas que funcionam como gatilho para a evasão escolar?". O objetivo era descobrir se o desempenho em matérias do ciclo básico seria o determinante para o aluno abandonar o curso.

2) No início do projeto, o que vocês acreditavam explicar a evasão?

No início do projeto, nós acreditávamos que a evasão era explicada principalmente pelo desempenho nas disciplinas difíceis do início do curso, como Cálculo I, Cálculo II, Álgebra Linear e Física.

Imaginamos que essas matérias funcionavam como um "choque inicial". A lógica era de que o alto grau de exigência e as reprovações logo no primeiro semestre geravam uma forte desmotivação emocional. Além disso, por serem pré-requisitos, essas disciplinas travavam o avanço do aluno na grade curricular, fazendo com que ele ficasse atrasado, se desanimasse e acabasse desistindo do curso.

3) Os dados confirmaram a ideia inicial? Justificar.

Não, os dados não confirmaram a ideia inicial. Nós acreditávamos que o "choque inicial" e as reprovações em disciplinas como Cálculo I e Álgebra Linear validariam estatisticamente a decisão de evasão.

No entanto, ao rodar a modelagem por Regressão Logística, nós notamos que o modelo matemático se mostrou incapaz de detectar quem está prestes a desistir utilizando apenas as aprovações e reprovações dessas matérias iniciais. Isso provou que a evasão ocorre de forma massiva logo nos primeiros semestres, afetando de forma muito semelhante tanto os alunos que reprovaram quanto aqueles que conseguiram ser aprovados nas disciplinas iniciais. O desempenho escolar isolado nessas matérias não é o fator preditivo principal.

4) Houve algum resultado que contradisse o que vocês imaginavam?

Sim. O modelo de Regressão Logística acabou apontando coeficientes negativos para algumas matérias importantes (o oposto do que se imaginava). Isso reforçou o padrão de que o problema da desistência vai além de simplesmente "ir mal" em Cálculo ou Álgebra. Alunos com aprovação nessas fases iniciais também evadiram massivamente entre o 1º e o 3º semestre, o que contradiz a ideia de que a reprovação acadêmica precoce seria a causa

isolada ou o principal motor da evasão.

5) Se vocês reiniciassem o projeto hoje, fariam algo diferente?

As principais mudanças em uma nova versão seriam:

- Mudar o foco dos dados acadêmicos puros para dados de comportamento e contexto: Em vez de tentar prever a evasão usando apenas aprovações/reprovações de disciplinas, seria fundamental incluir o total de faltas em tempo real (que se mostrou crítico).
- Adicionar novas variáveis cruciais: Coletar dados socioeconômicos (como renda e se o aluno possui bolsas) e mais dados de perfil (como detalhes de deslocamento) para entender o impacto financeiro e social na permanência.
- Tratamento de Algoritmo: Aplicar técnicas avançadas de balanceamento de dados no código, visto que a base histórica do projeto tinha 71,7% de não desistentes e 28,3% de desistentes. Esse desbalanceamento gerou um modelo ingênuo que tendeu a falhar na identificação correta da classe minoritária (quem realmente desiste).

6) Alguma descoberta chamou atenção por parecer contraintuitiva?

A descoberta mais marcante e contraintuitiva foi a variável de Distância da Cidade. O senso comum sugeriria que morar mais longe traria mais desgaste e aumentaria o risco de desistência. Porém, os dados mostraram exatamente o oposto:

- A mediana de distância de quem desistiu (evasores) foi de 0 km (ou seja, a maioria morava na mesma cidade da instituição) .
- Os alunos que permaneceram (não evasores) residiam, em média, mais longe (média de 19,44 km contra 8,14 km dos evasores).

A conclusão foi que a distância física aumenta o planejamento, o investimento emocional e financeiro do estudante, gerando um compromisso muito mais robusto com o curso. Já para quem mora perto, o "custo de desistência" é menor.

7) Existe alguma variável que parece muito importante? Por quê?

Sim, algumas variáveis se mostraram importantes:

- O Momento do Curso (Fator Estrutural / Tempo): A evasão é massiva no início da jornada acadêmica, concentrando-se fortemente entre o 1º e o 3º semestre. Foram mapeados 207 eventos de evasão no primeiro semestre de cada ano contra apenas 78 no segundo semestre. Isso prova que o período de adaptação é o momento mais crítico.
- Gênero (Sexo): Os homens evadem significativamente mais do que as mulheres. A taxa de evasão masculina foi de 29,5%, enquanto a feminina foi de 18,2% , indicando uma vulnerabilidade estatística bem clara no grupo masculino dentro das

engenharias.

- Número de Faltas (Como sinal de alerta): Passar de 10 faltas dobra o risco de desistência. Porém, é preciso atenção: as faltas funcionam como um sinal tardio, pois costumam disparar apenas a partir da 4ª fase, quando o aluno já se desengaja.

8) Existe alguma variável que parecia importante, mas acabou não sendo?

A Idade dos estudantes. Imaginava-se que a idade (alunos mais novos saindo do ensino médio vs. alunos mais velhos retornando) pudesse influenciar o comportamento de desistência. Contudo, a análise descritiva revelou que a média de idade foi praticamente idêntica em ambos os grupos: ~22,54 anos para quem ficou e ~22,57 anos para quem saiu. Portanto, ela se provou irrelevante para prever o risco de abandono.

Parte 2 - AVALIAÇÃO DO MODELO

9) Qual métrica apresentou melhor resultado?

Accuracy (Acurácia): 72,00% . Foi o maior valor numérico absoluto apresentado entre as métricas de avaliação.

Precision (Precisão) e F1-score: Como o modelo classificou todos os alunos da base de teste como "não desistentes" (classe 0) , ele não fez nenhuma previsão positiva para a classe de evasão (classe 1). Portanto, o valor de verdadeiros positivos é 0, inviabilizando ou zerando a precisão para os desistentes.

Recall (Revocação): Foi de 1,00 (100%) para a classe 0 (não desistentes), mas foi de **0,00 (0%) para a classe 1** (desistentes) , que é o foco principal do problema.

10) Qual erro parece mais preocupante: falso positivo ou falso negativo? Justifique no contexto da faculdade.

O Falso Negativo é o mais preocupante

Por que o Falso Negativo é o erro mais preocupante?

O Impacto Direto nas Disciplinas-Gatilho

- **O que acontece no Falso Negativo:** O modelo prevê que um aluno continuará no curso (não vai desistir), mas, na realidade, ele acaba evadindo.
- **A relação com o tema:** Se o aluno está matriculado em uma disciplina considerada "filtro" ou "gatilho" (como Cálculo I ou Álgebra Linear) e está demonstrando sinais de extrema dificuldade ou abandono, o modelo vai ignorar esse risco.
- **A consequência:** A faculdade assume que o estudante está bem.
- Com isso, o aluno enfrenta o "choque inicial" e o estresse dessas matérias sem nenhum suporte, o que o leva a desistir permanentemente da instituição sem que ninguém tenha percebido o perigo a tempo.

A Perda do Tempo de Reação (Inação da Faculdade)

- Quando ocorre um falso negativo, a instituição perde completamente a janela de oportunidade para agir de forma preventiva.
- Como o objetivo prático do projeto é usar o modelo para criar um "farol de risco" e oferecer intervenções de acolhimento (como mentorias e suporte pedagógico nas disciplinas complexas), o falso negativo anula essa estratégia, deixando os alunos mais vulneráveis desamparados.

Por que o Falso Positivo é menos grave neste contexto?

- **O que acontece no Falso Positivo:** O modelo acusa que o aluno vai desistir, mas, na verdade, ele continuaria no curso.
- **O "prejuízo":** Se o modelo errar para um falso positivo, a coordenação da faculdade apenas gastará um pouco de energia enviando uma mensagem de apoio, oferecendo uma monitoria de Cálculo ou direcionando o estudante para um programa de acolhimento. No pior dos cenários, um aluno que já estava bem receberá uma ajuda extra da instituição, o que nunca é um resultado verdadeiramente negativo.

Parte 3 – LIMITAÇÕES DO PROJETO

11) Quais informações importantes não existiam no dataset, que você consideraria fazer uma nova pesquisa, caso pudesse?

Exemplos: situação financeira, necessidade de trabalhar, saúde mental, motivação.

- **O que faltou:** Dados sobre a renda familiar, se o estudante possui alguma bolsa de estudos ou financiamento, e principalmente se ele precisa trabalhar em turno integral.

Nível de Engajamento Real e Faltas no Início do Semestre

- **O que faltou:** O total de faltas detalhado ao longo das primeiras semanas e o histórico de acessos ao portal acadêmico (Ambiente Virtual de Aprendizagem).

Aspectos Comportamentais e de Saúde Mental (Motivação)

- **O que faltou:** Pesquisas de satisfação iniciais, nível de certeza sobre a escolha do curso (motivação) ou relatos de estresse e ansiedade.

12) Alguma decisão tomada na limpeza dos dados pode ter influenciado os resultados?

A Estratégia de Imputação (Preenchimento de Nulos)

Quando existem dados faltando (NaN/Null), as decisões mais comuns são deletar as linhas ou preenchê-las (com a média, mediana ou a moda).

O impacto: Se você preenche valores nulos usando a média ou a moda, você está adicionando dados artificiais que reduzem a variabilidade natural do dataset. O modelo pode começar a enxergar um padrão "comportado" e previsível que não existe no mundo real, diminuindo sua capacidade de lidar com casos extremos ou fora do padrão.

Remoção de Outliers (Valores Extremos)

É muito comum apagar registros que fogem demais do padrão (por exemplo, um aluno com uma quantidade absurdamente alta de faltas ou uma idade muito acima da média da turma).

O impacto: Embora os outliers possam atrapalhar algoritmos sensíveis (como a Regressão Logística e a Regressão Linear), removê-los pode fazer com que o modelo perca a capacidade de prever justamente os casos mais raros e críticos.

Em problemas de detecção de anomalias ou riscos, o outlier costuma ser a informação mais valiosa.

Manutenção do desbalanceamento original da base

A decisão: Durante a limpeza e preparação dos dados, a base foi mantida com a sua proporção original de distribuição das classes (71,7% de não desistentes contra 28,3% de desistentes), sem a aplicação de técnicas de balanceamento (como SMOTE ou subamostragem).

O impacto no comportamento do modelo: Essa escolha influenciou diretamente o modelo a se tornar extremamente conservador e tendencioso. Por ter muito mais exemplos de quem ficou no curso, o algoritmo especializou-se em reconhecer a classe majoritária e simplesmente "chutou" que todos os 25 alunos do teste continuariam na faculdade, gerando uma acurácia alta, porém totalmente ilusória.

Parte 4 - Pensando como cientistas de dados apresentando para a coordenação/chefia, responda:

13) Qual problema principal vocês identificaram?

O problema principal é o **alto índice de evasão concentrado no período de adaptação inicial do curso**, especificamente entre o 1º e o 3º semestre (fases 1 a 3), combinado com a ausência de sinais de alerta precoces e visíveis que permitam à instituição agir antes que o abandono se torne irreversível.

A análise histórica revela um padrão particularmente difícil de combater: no período de maior risco, o aluno em processo de desengajamento ainda comparece às aulas, ainda acumula poucas faltas e, em muitos casos, ainda está sendo aprovado nas disciplinas do ciclo básico. Isso torna o risco praticamente invisível pelos indicadores tradicionais de acompanhamento acadêmico.

14) Qual evidência sustenta essa conclusão?

As evidências vêm diretamente dos dados históricos dos quatro datasets analisados (2019.1 a 2023.1):

- **Concentração temporal:** 28 alunos evadiram nas fases 1 a 3, representando mais do dobro dos 8 que evadiram nas fases 7 a 9. Nos semestres letivos, foram 207 eventos de evasão nos primeiros semestres de cada ano contra apenas 78 nos segundos semestres.
- **Faltas como sinal tardio:** Nas fases 1 e 2, os alunos que viriam a desistir tinham média de faltas menor (0,77) do que os que permaneceram (1,83). As faltas só disparam a partir da fase 4, quando o desengajamento já está avançado e a decisão de evadir provavelmente já foi tomada.
- **Desempenho insuficiente como preditor isolado:** Alunos que evadiram apresentaram nota média de 7,42 contra 7,78 dos que permaneceram, uma diferença sutil que indica que muitos desistiram mesmo com desempenho razoável. Isso ficou comprovado pelo modelo preditivo, que ao usar apenas aprovações e reprovações obteve Recall 0% para a classe de desistentes.
- **Perfil de risco:** Homens evadiram a uma taxa de 29,5% contra 18,2% das mulheres. Alunos que residem na cidade da instituição (mediana de 0 km) evadem mais do que os que moram longe (média de 19,44 km para quem permaneceu), sugerindo que a proximidade física reduz o custo percebido da desistência.

15) Qual ação a instituição deveria realizar?

Implementar um "**Farol de Risco**" **preventivo** baseado em padrões históricos, combinado com um programa de acolhimento humano e pedagógico, estruturado em duas frentes:

- **Frente pedagógica:** Oferecer mentorias e suporte nas disciplinas do ciclo básico (Cálculo I, Álgebra Linear, Física I, Fundamentos de Química e Comunicação e Expressão) para todos os ingressantes das fases 1 a 3, independentemente de já terem reprovado ou não. Os dados mostram que muitos alunos evadem mesmo aprovados nessas matérias, portanto esperar a reprovação para agir é tarde demais.
- **Frente de acolhimento:** Criar um protocolo de contato proativo com alunos que apresentem acúmulo de faltas acima de 10 em qualquer disciplina, sem esperar que o próprio aluno sinalize intenção de desistir. Esse limite foi identificado nos dados como o ponto em que o risco de evasão dobra.

16) Em que momento essa ação deveria acontecer?

A intervenção deve ocorrer nos **primeiros 30 a 60 dias de cada semestre letivo**, com foco nos alunos ingressantes nas fases 1 a 3. Os dados mostram que o semestre 2019.1 sozinho concentrou 51 eventos de evasão, e que os primeiros semestres de cada ano concentram consistentemente quase três vezes mais eventos do que os segundos semestres (207 contra 78).

17) Quem seria responsável por essa intervenção?

A **Coordenação do Curso**, com o monitoramento dos indicadores históricos (taxas de reprovação por disciplina, volume de faltas por fase, perfil de alunos ingressantes) em parceria com a **área de Psicopedagogia**, para garantir que o acolhimento seja tanto pedagógico (tutoria) quanto emocional/estrutural.

18) Qual impacto vocês esperam?

Espera-se a redução da taxa de evasão precoce e o aumento da retenção, ao identificar o aluno em risco antes que ele acumule faltas ou reprovações que o levem ao abandono definitivo.

Parte 5 - PLANEJANDO O DASHBOARD

19) Para planejar o dashboard, pense sobre isso, respondendo:

- **Qual pergunta o dashboard precisa responder?**

"Quais padrões históricos de evasão existem e quais disciplinas apresentaram maior taxa de gargalo entre 2019 e 2023?"

Fonte dos dados: clean_data (desistiu, sexo, dist_cidade_km), dadosAprovacao (fase, nome_disc, resultado, numero_falta), dadosMatriculas (semestre), dadosAlunos (i_saida).

- **Se alguém olhar o dashboard por apenas 30 segundos, o que deveria entender?**

Deveria identificar imediatamente três coisas: qual fase do curso concentra mais evasão, qual é a tendência semestre a semestre ao longo dos anos analisados, e quais disciplinas apresentaram as maiores taxas de reprovação no período.

Esses três elementos são obtidos diretamente de dadosAprovacao (fase, resultado, nome_disc) cruzado com clean_data (desistiu) e dadosMatriculas (semestre).

- **Se a coordenação pudesse visualizar apenas uma tela, o que deveria estar nela?**

Deve conter gráficos com o volume de alunos evadidos por fase do curso (evidenciando a concentração nas fases 1 e 3) e um ranking das disciplinas com maior taxa histórica de reprovação.

- **Quais são as três informações mais importantes que a coordenação precisa conhecer?**

1. **Evasão por fase do curso**

O que mostra: distribuição de alunos evadidos por fase (1 a 9), evidenciando que as fases 1 a 3 concentram a maior parte das saídas totais.

Por que é importante: permite à coordenação direcionar esforços de acolhimento para o período mais crítico, em vez de distribuir recursos igualmente ao longo de todo o curso.

Fonte: dadosAprovacao (fase) + clean_data (desistiu).

2. **Faltas por fase**

O que mostra: média de faltas por fase separando os dois grupos. Evidencia que nas fases 1 e 2 os desistentes têm menos faltas do que os que ficam (0,77 contra 1,83), e que a inversão só ocorre após a fase 4.

Por que é importante: desfaz o pressuposto de que faltas são um indício precoce confiável, e orienta a coordenação a não esperar esse sinal específico para agir.

Fonte: dadosAprovacao (numero_falta, fase) + clean_data (desistiu).

3. **Taxa de reprovação por disciplina**

O que mostra: percentual histórico de reprovação por disciplina, com destaque para Sistemas Eletrônicos (34,19% de reprovação e média 5,52) e as demais disciplinas do ciclo básico.

Por que é importante: orienta a criação de grupos de monitoria e reforço nas matérias com maior histórico de gargalo, de forma objetiva e baseada em dados.

Fonte: dadosAprovacao (nome_disc, resultado).

- **Quais gráficos ou indicadores seriam mais adequados? Por que esse gráfico ajuda a entender a informação?**

- **KPI (Cards):** Total de alunos evadidos no período 2019-2023.
- **Gráfico de Colunas: Evasão por fase do curso**

O que exhibe: número de alunos evadidos por fase.

Por que ajuda: Torna imediata a conclusão de que a evasão se concentra nas fases iniciais, justificando onde concentrar os recursos de retenção.

- **Gráfico de Linhas: Média de faltas por fase**

O que exhibe: evolução da média de faltas da fase 1 à 9, para os alunos desistentes e não desistentes.

Por que ajuda: Evidencia o cruzamento das trajetórias após a fase e explica porque as faltas não servem como alerta precoce .

- **Gráfico de Barras: Disciplinas com maior reprovação**

O que exhibe: ranking das 10 disciplinas com maior percentual histórico de reprovação.

Por que ajuda: Identifica diretamente os gargalos pedagógicos e orienta a alocação de monitoria e suporte de forma objetiva.

- **Gráfico de Barras: Evasão por semestre letivo (2019.1 a 2023.1)**

O que exhibe: volume de eventos de evasão por semestre, com diferenciação visual entre primeiros e segundos semestres de cada ano.

Por que ajuda: Evidencia o padrão de mais evasões nos primeiros semestres, justificando o foco no início do ano letivo como período de maior risco.

- **Gráfico de Barras: Evasão por gênero**

O que exhibe: taxa de evasão comparando os grupos masculino e feminino

Por que ajuda: Sinaliza que alunos do gênero masculino constituem um subgrupo de maior vulnerabilidade estatística, orientando ações de retenção específicas para esse perfil.